

# 模式识别

## 第二章 贝叶斯决策理论

北京航空航天大学计算机学院

# 内容

- \* 引言
- \* 几种常见的决策规则
- \* 正态分布时的统计决策

# 引言

- \* 贝叶斯决策理论是统计模式识别中最基本的方法，利用此方法进行分类时要求：
  - \* 各类别总体的概率分布是已知的
  - \* 待决策分类的类别数是一定的
- \* 统计决策理论——根据每一类总体的概率分布决定决策边界

# 引言

## 基本符号与定义

- \* 在连续的情况下，假设对要识别的物理对象有d种特征观察量

$$x_1, x_2, \dots, x_d$$

- \* 这些特征的所有可能的取值范围构成了d维空间

$$x = [x_1, x_2, \dots, x_d]^T$$

- \* 我们又称x为d维特征向量

# 引言

## 基本符号与定义

- \* 假设要分类的问题有 $c$ 个类别，各类别状态用  $\omega_i$  来表示，其中  $i = 1, 2, \dots, c$
- \* 且对应于各类别的  $\omega_i$  出现的先验概率  $P(\omega_i)$  及类条件概率密度  $p(x | \omega_i)$  已知
- \* 如果在特征空间已经观察到某一个向量 $x$ , 应该把 $x$ 分到哪一类?

# 引言

## 基本符号与定义

- \* 例：医生要根据病人血液中白细胞的浓度来判断病人是否患血液病。（两分类问题）
- \* 根据以往医生的经验知道：
  - \* 患病的人，白细胞的浓度与正常人不同
  - \* 一般人群中，患病的人数比例为0.1。
- \* 如果已知一个人的白细胞浓度，医生应该做出怎样的判断？

# 引言

## 基本符号与定义

- \* 对该问题的数学表示如下:
- \* 用 $\Omega$ 表示“类别”这一随机变量,  $\omega_1$ 表示正常,  $\omega_2$ 表示患病
- \*  $X$ 表示“白细胞浓度”这个随机变量
- \*  $x$ 表示浓度值

# 引言

## 基本符号与定义

\* 医生的先验概率:

$$P(\omega_1) = 0.9$$

$$P(\omega_2) = 0.1$$

\* 观测数据白细胞浓度分别在两种情况下的类条件分布:

$$p(x | \omega_1)$$

$$p(x | \omega_2)$$



# 引言

## 基本符号与定义

- \* 决策：根据观测到的 $x$ , 利用先验概率和类条件概率，决定 $x$ 属于哪一类
- \* 决策是从样本空间到决策空间的一个映射
- \* 评价决策有多种标准，对于同一个问题，采用不同的标准会得到不同意义下“最优”的决策。

# 引言

## 基本符号与定义

- \* Bayes决策是所有识别方法的一个基准
- \* Bayes决策两种常用的准则：
  - \* 最小错误概率准则
  - \* 最小风险准则

# 几种常见的决策规则


## 基于最小错误概率的贝叶斯决策

- \* 前面的问题，已知先验概率和类条件概率密度，利用贝叶斯公式，求得后验概率

$$p(\omega_i | x) = \frac{p(x | \omega_i)P(\omega_i)}{\sum_{j=1}^2 p(x | \omega_j)P(\omega_j)}$$

# 几种常见的决策规则

## 基于最小错误概率的贝叶斯决策



类条件概率密度函数

后验概率

# 几种常见的决策规则

## 基于最小错误概率的贝叶斯决策

- \* 决策规则

- \* (1)  $P(\omega_i|x) = \max_{j=1,2} P(\omega_j|x), x \in \omega_i$

# 几种常见的决策规则

## 基于最小错误概率的贝叶斯决策

\* 其他等价形式

\* (2)  $p(x|\omega_i)P(\omega_i) = \max_{j=1,2} P(x|\omega_j)P(\omega_i)$

\* (3) 若  $l(x) = \frac{p(x|\omega_1)}{p(x|\omega_2)} \geq \frac{P(\omega_2)}{P(\omega_1)}$

则  $x \in \frac{\omega_1}{\omega_2}$

# 几种常见的决策规则

## 基于最小错误概率的贝叶斯决策

\* (4)对上式取自然对数的负值,可写为

$$h(x) = -\ln(l(x))$$

$$= -\ln p(x|\omega_1) + \ln p(x|\omega_2) \geq \ln \frac{P(\omega_1)}{P(\omega_2)}$$

$$\text{则 } x \in \frac{\omega_1}{\omega_2}$$

# 几种常见的决策规则

## 基于最小错误概率的贝叶斯决策

- \* 例题: 前面讲到的白血病检验问题
- \* 现有一待识别细胞, 观察值为 $x$ , 从类条件概率密度分布曲线上查得
$$p(x|\omega_1) = 0.2 \quad p(x|\omega_2) = 0.4$$
- \* 对该细胞进行分类



# 几种常见的决策规则

## 基于最小错误概率的贝叶斯决策

\* 利用贝叶斯公式，分别计算后验概率

$$\begin{aligned} P(\omega_1|x) &= \frac{p(x|\omega_1)P(\omega_1)}{\sum_{j=1}^2 p(x|\omega_j)P(\omega_j)} \\ &= \frac{0.2 * 0.9}{0.2 * 0.9 + 0.4 * 0.1} = 0.818 \\ P(\omega_2|x) &= 1 - P(\omega_1|x) = 0.182 \\ P(\omega_1|x) &> P(\omega_2|x) \end{aligned}$$

\* 故该细胞是正常的

# 几种常见的决策规则

## 基于最小错误概率的贝叶斯决策

- \* 下面以一维情况证明上述贝叶斯决策规则使错误率最小
- \* 错误率：此处为平均错误率
- \* 
$$P(e) = \int_{-\infty}^{+\infty} P(e, x) dx = \int_{-\infty}^{+\infty} P(e|x)p(x) dx$$

# 几种常见的决策规则

## 基于最小错误概率的贝叶斯决策

- 条件错误率  $P(e|x)$  的计算:
  - 以两类问题为例, 当获得观测值  $x$  后, 有两种决策可能: 决定  $x \in \omega_1$ , 或者  $x \in \omega_2$ .  
条件错误率为:

$$P(e|x) = \begin{cases} P(\omega_2 | x) = 1 - P(\omega_1 | x) & \text{若决定 } x \in \omega_1 \\ P(\omega_1 | x) = 1 - P(\omega_2 | x) & \text{若决定 } x \in \omega_2 \end{cases}$$

# 几种常见的决策规则

## 基于最小错误概率的贝叶斯决策

- Bayes最小错误率决策:

- 选择后验概率 $P(\omega_1 | x), P(\omega_2 | x)$ 中大的 $\omega$ 作为决策, 使得在观测值 $x$ 下的条件错误率最小。

$$D(x) = \arg \max_i P(\omega_i | x).$$

- 条件错误率:


$$P(e | x) = 1 - \max_i P(\omega_i | x).$$

- 错误率:

$$P(e) = E(P(e | x)).$$

# 几种常见的决策规则

## 基于最小错误概率的贝叶斯决策



# 几种常见的决策规则

## 基于最小错误概率的贝叶斯决策

$$\begin{aligned} p(e) &= p(x \in \mathcal{R}_1, \omega_2) + p(x \in \mathcal{R}_2, \omega_1) \\ &= p(x \in \mathcal{R}_1 | \omega_2) p(\omega_2) + p(x \in \mathcal{R}_2 | \omega_1) p(\omega_1) \\ &= p(\omega_2) p_2(e) + p(\omega_1) p_1(e) \end{aligned}$$

- \* 此决策实际上对每个 $x$ 都使 $P(e|x)$ 取最小
- \* 从而保证上式最小
- \* 由此证明了最小错误率贝叶斯规则确实使错误率最小

# 几种常见的决策规则

## 基于最小错误概率的贝叶斯决策

Bayes最小错误率决策不仅保证了错误率（条件错误率的期望）最小，而且保证每个观测值下的条件错误率最小，Bayes决策是一致最优决策。

# 几种常见的决策规则

## 基于最小错误概率的贝叶斯决策

多类识别问题的Bayes最小错误率决策:

- 在观测值  $x$  下的每个决策的条件错误率为:

$$P(e | x) = 1 - P(\omega_i | x) \quad \text{若决定 } x \in \omega_i$$

- 决策为:

$$D(x) = \arg \max_i P(\omega_i | x).$$



# 几种常见的决策规则

## 基于最小错误概率的贝叶斯决策

后验概率 $P(\omega_i | x)$ 的计算:

■ Bayes公式:

$$P(\omega_i | x) = \frac{p(x | \omega_i)P(\omega_i)}{p(x)}$$

$$= \frac{p(x | \omega_i)P(\omega_i)}{\sum_i p(x | \omega_i)P(\omega_i)}.$$

■  $P(\omega_i)$  : 先验概率;  $p(x | \omega_i)$ : 类条件概率密度。

# 几种常见的决策规则

## 基于最小错误概率的贝叶斯决策

$$P(e) = \left[ \begin{aligned} &P(\vec{x} \in \mathcal{R}_2 | \omega_1) + P(\vec{x} \in \mathcal{R}_3 | \omega_1) + \dots + P(\vec{x} \in \mathcal{R}_c | \omega_1) \\ &+ [P(\vec{x} \in \mathcal{R}_1 | \omega_2) + P(\vec{x} \in \mathcal{R}_3 | \omega_2) + \dots + P(\vec{x} \in \mathcal{R}_c | \omega_2)]P(\omega_2) \\ &+ \dots \\ &+ [P(\vec{x} \in \mathcal{R}_1 | \omega_c) + P(\vec{x} \in \mathcal{R}_2 | \omega_c) + \dots + P(\vec{x} \in \mathcal{R}_{c-1} | \omega_c)]P(\omega_c) \end{aligned} \right] \left. \vphantom{\begin{aligned} &P(\vec{x} \in \mathcal{R}_2 | \omega_1) + P(\vec{x} \in \mathcal{R}_3 | \omega_1) + \dots + P(\vec{x} \in \mathcal{R}_c | \omega_1) \\ &+ [P(\vec{x} \in \mathcal{R}_1 | \omega_2) + P(\vec{x} \in \mathcal{R}_3 | \omega_2) + \dots + P(\vec{x} \in \mathcal{R}_c | \omega_2)]P(\omega_2) \\ &+ \dots \\ &+ [P(\vec{x} \in \mathcal{R}_1 | \omega_c) + P(\vec{x} \in \mathcal{R}_2 | \omega_c) + \dots + P(\vec{x} \in \mathcal{R}_{c-1} | \omega_c)]P(\omega_c) \right.} \right\} c \text{行}$$

每行  $c-1$  项

$$= \sum_{i=1}^c \sum_{j=1, j \neq i}^c [P(\vec{x} \in \mathcal{R}_j | \omega_i)]P(\omega_i)$$

# 几种常见的决策规则

## 基于最小错误概率的贝叶斯决策

$$P(c) = \sum_{j=1}^c P(\vec{x} \in \mathcal{R}_j | \omega_j) P(\omega_j) = \sum_{j=1}^c \int_{\mathcal{R}_j} p(\vec{x} | \omega_j) P(\omega_j) d\vec{x}$$

$$P(e) = 1 - P(c)$$

# 几种常见的决策规则

## 基于最小风险的贝叶斯决策

- \* 每个决策的风险是不同的，我们在决策过程中应该考虑决策风险
- \* 以疾病诊断为例，风险大不相同

# 几种常见的决策规则

## 基于最小风险的贝叶斯决策

- \* 如何在决策中考虑风险?
- \* 引入风险函数（损失函数），通常是决策和自然状态的函数，可用决策表来表示

# 几种常见的决策规则

## 基于最小风险的贝叶斯决策

■ N类问题:  $(\lambda_{i,j})_{N \times N}$

$$\begin{pmatrix} \lambda_{11} & \lambda_{12} & \lambda_{13} & \lambda_{14} & \cdots & \lambda_{1n} \\ \lambda_{21} & \lambda_{22} & & \cdots & & \lambda_{2n} \\ & & \ddots & & & \\ \vdots & & \lambda_{ij} & & \vdots & \\ \lambda_{(n-1)1} & & & & \lambda_{(n-1)n} \\ \lambda_{n1} & \lambda_{n2} & \cdots & & \lambda_{nn} \end{pmatrix}$$

表示当我们给出的决策为i类，而真实类别为j时的损失值。

# 几种常见的决策规则

## 基于最小风险的贝叶斯决策

\* 以数学形式表示决策问题:

\* (1) 观察 $x$ 是 $d$ 维随机向量

$$x = [x_1, x_2, \dots, x_d]^T$$

\* (2) 状态空间 $\Omega$ 由 $c$ 个自然状态组成

$$\Omega = [\omega_1, \omega_2, \dots, \omega_c]^T$$

# 几种常见的决策规则

## 基于最小风险的贝叶斯决策

\* (3) 决策空间由 $a$ 个决策组成

$$A = \{a_1, a_2, \dots, a_a\}$$

\* (4) 损失函数为 $\lambda$



# 几种常见的决策规则

## 基于最小风险的贝叶斯决策

\* 根据贝叶斯公式,

$$P(\omega_j|x) = \frac{p(x|\omega_j)P(\omega_j)}{p(x)}$$

\* 其中

$$p(x) = \sum_{i=1}^c p(x|\omega_i)P(\omega_i)$$

# 几种常见的决策规则

## 基于最小风险的贝叶斯决策

- \* 在引入损失函数后, 对应于决策 $a_i$ ,  $\lambda$ 可以在 $c$ 个 $\lambda(a_i, \omega_j), j = 1, 2, \dots, c$  中任意选取一个, 相应的概率为 $P(\omega_j|x)$
- \* 故采用决策 $a_i$ 时的条件期望损失是
- \*  $R(a_i|x) = E[\lambda(a_i, \omega_j)] = \sum_{j=1}^c \lambda(a_i, \omega_j)P(\omega_j|x), i = 1, 2, \dots, a$

# 几种常见的决策规则

## 基于最小风险的贝叶斯决策

- \*  $x$  是随机变量，采用  $x$  不同的观测值，产生的条件风险不同，决策  $a$  可以看成是  $x$  的函数，我们定义期望风险

$$R = \int R(a(x)|x)p(x)dx$$

- \* 条件风险对应的是  $x$ ，期望风险对应的是  $a(x)$

# 几种常见的决策规则

## 基于最小风险的贝叶斯决策

\* 在考虑错判带来的损失时，我们希望损失最小，如果在采取每个决策，都使其条件风险最小，则对所有的 $x$ 作出决策时，其期望风险也必然最小。这样的决策就是最小风险贝叶斯决策。

\* 最小风险贝叶斯决策规则为：

如果  $R(a_k|x) = \min_{i=1,\dots,a} R(a_i|x)$   
则  $a = a_k$

# 几种常见的决策规则

## 基于最小风险的贝叶斯决策

- \* 具体计算步骤如下:
- \* (1) 计算后验概率
- \* (2) 根据决策风险表, 计算出采取 $a_i$ 的条件风险

$$\begin{aligned} R(a_i|x) &= E[\lambda(a_i, \omega_j)] \\ &= \sum_{j=1}^c \lambda(a_i, \omega_j) P(\omega_j|x), i = 1, 2, \dots, a \end{aligned}$$

# 几种常见的决策规则

## 基于最小风险的贝叶斯决策

- \* (3) 对 $a$ 个条件风险值进行比较, 找出使条件风险最小的决策 $a$

$$R(a_k|x) = \min_{i=1,\dots,a} R(a_i|x)$$

- \* 则 $a_k$ 就是最小风险贝叶斯决策

# 几种常见的决策规则

## 基于最小风险的贝叶斯决策

\* 以前面例题为例

\* 已知：

$$P(\omega_1) = 0.9, P(\omega_2) = 0.1$$

$$P(x|\omega_1) = 0.2, P(x|\omega_2) = 0.4$$

$$\lambda_{11} = 0, \lambda_{12} = 6$$

$$\lambda_{21} = 1, \lambda_{22} = 0$$

# 几种常见的决策规则

## 基于最小风险的贝叶斯决策

\* 利用贝叶斯公式，分别计算后验概率

$$\begin{aligned} P(\omega_1|x) &= \frac{p(x|\omega_1)P(\omega_1)}{\sum_{j=1}^2 p(x|\omega_j)P(\omega_j)} \\ &= \frac{0.2 * 0.9}{0.2 * 0.9 + 0.4 * 0.1} = 0.818 \\ P(\omega_2|x) &= 1 - P(\omega_1|x) = 0.182 \\ P(\omega_1|x) &> P(\omega_2|x) \end{aligned}$$



# 几种常见的决策规则

## 基于最小风险的贝叶斯决策

- \* 引入风险函数后，计算条件风险

$$R(a_1|x) = \sum_{j=1}^c \lambda_{1j} P(\omega_j|x) = \lambda_{12} P(\omega_2|x) \\ = 1.092$$

$$R(a_2|x) = \lambda_{21} P(\omega_1|x) = 0.818$$

- \* 因为  $R(a_1|x) > R(a_2|x)$
- \* 故选择决策行动  $a_2$  即该细胞为异常

# 几种常见的决策规则

## 基于最小风险的贝叶斯决策

- \* 小作业：最小错误率的贝叶斯决策和最小风险贝叶斯决策的关系？（证明）

# 几种常见的决策规则

## 分类器设计

- \* 应用最小错误率贝叶斯决策准则的分类器设计
- \* 分类器设计问题为确定判别函数和决策面
- \* 对于 $c$ 类分类问题，按照决策规则可以把 $d$ 维特征空间分成 $c$ 个决策域，我们将划分决策域的边界面称为决策面，在数学上用解析形式可以表示成决策面方程，用于表达决策规则的某些函数称为判别函数。

# 几种常见的决策规则

## 多类情况的贝叶斯决策规则

\* (1)  $P(\omega_i|x) > P(\omega_j|x), j = 1, 2, \dots, c, j \neq i$

则  $x \in \omega_i$

\* (2)  $p(x|\omega_i)P(\omega_i) > p(x|\omega_j)P(\omega_j), j = 1, 2, \dots, c, j \neq i$ , 则  $x \in \omega_i$

# 几种常见的决策规则

## 多类情况的贝叶斯决策规则

\* (3)  $l(x) = \frac{p(x|\omega_i)}{p(x|\omega_j)} > \frac{P(\omega_j)}{P(\omega_i)}, j = 1, 2, \dots, c, j \neq i$ , 则  $x \in \omega_i$

\* (4)  $\ln p(x|\omega_i) + \ln P(\omega_i) > \ln p(x|\omega_j) + \ln P(\omega_j), j = 1, 2, \dots, c, j \neq i$ , 则  $x \in \omega_i$

# 几种常见的决策规则

## 判别函数

- \* 判别函数: 通常定义一组判别函数 $g_i(x)$ ,  $i = 1, 2, \dots, c$ , 用来表示多类决策规则:
- \* 如果使得 $g_i(x) > g_j(x)$  对于一切的 $j \neq i$ 均成立, 则将 $x$ 归于 $\omega_i$ 类。

# 几种常见的决策规则 判别函数

- \* 相对应于贝叶斯决策的判别函数
- \* (1)  $g_i(x) = P(\omega_i|x)$
- \* (2)  $g_i(x) = p(x|\omega_i)P(\omega_i)$
- \* (3)  $g_i(x) = \ln p(x|\omega_i) + \ln P(\omega_i)$

# 几种常见的决策规则

## 决策面方程&分类器设计

- \* 决策面方程

$$g_i(x) = g_j(x)$$


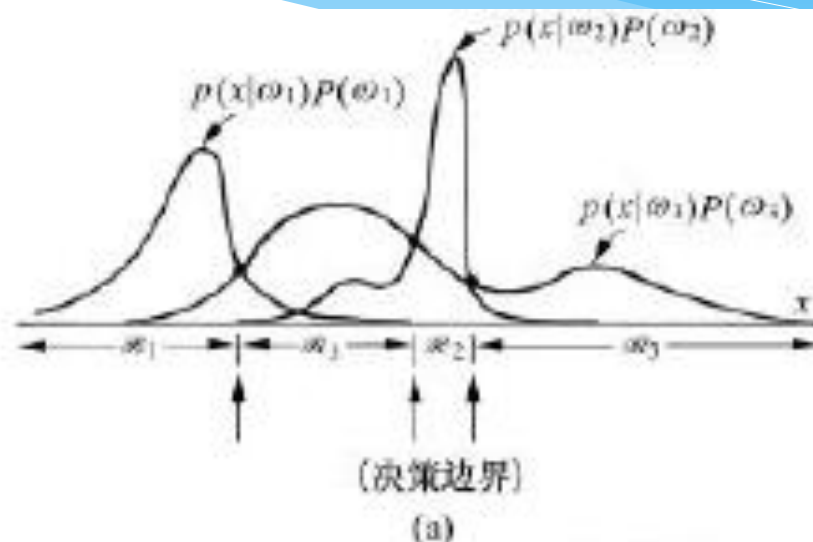
- \* 分类器设计原则

- \* 选取最大的 $g(x)$



# 几种常见的决策规则

## 决策面方程&分类器设计



# 正态分布时的统计决策

- \* 在统计决策分析中经常假定正态分布，因为：
  - \* 物理上的合理性
  - \* 正态分布的一些性质使在数学上计算简单

# 正态分布时的统计决策

- \* 物理上的合理性示例
  - \* 人的身高、寿命等
  - \* 考试成绩
  - \* 医学参考值
  - \* 信道噪声

# 正态分布时的统计决策

## 正态分布函数定义及性质

\* 单变量正态分布

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right\}$$

$$\mu = E\{x\} = \int_{-\infty}^{+\infty} xp(x)dx$$

$$\sigma^2 = \int_{-\infty}^{+\infty} (x-\mu)^2 p(x)dx$$

# 正态分布时的统计决策

## 正态分布函数定义及性质

\* 概率密度函数应满足下面关系：

$$p(x) \geq 0 (-\infty < x < +\infty)$$

$$\int_{-\infty}^{+\infty} p(x) dx = 1$$

# 正态分布时的统计决策

## 正态分布函数定义及性质

\* 多元正态分布

$p(x)$

$$= \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp\left\{-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu)\right\}$$

其中

$\mathbf{x} = [x_1, x_2, \dots, x_d]^T$  是d维列向量,

$\mu = [\mu_1, \mu_2, \dots, \mu_d]^T$  是d维均值向量,

$\Sigma$  是d\*d维的协方差矩阵

# 正态分布时的统计决策

## 正态分布函数定义及性质

$$\mu = E\{x\}$$

$$\Sigma = E\{(x - \mu)(x - \mu)^T\}$$

$$\sigma_{ij}^2 = E[(x_i - \mu_i)(x_j - \mu_j)]$$

$$\Sigma = \begin{matrix} & \sigma_{11}^2 & \sigma_{12}^2 & \cdots & \sigma_{1d}^2 \\ \sigma_{21}^2 & \sigma_{22}^2 & \cdots & \sigma_{2d}^2 \\ \cdots & \cdots & \cdots & \cdots \\ \sigma_{d1}^2 & \sigma_{d2}^2 & \cdots & \sigma_{dd}^2 \end{matrix}$$

# 正态分布时的统计决策

## 多元正态 - 判别函数和决策面

- \* 多元正态概率模型下的最小错误率贝叶斯判别函数和决策面

$$g_i(\mathbf{x}) = \ln \mathbf{p}(\mathbf{x}|\omega_i) + \ln \mathbf{P}(\omega_i)$$

- \* 正态分布时判别函数为

$$\begin{aligned} g_i(\mathbf{x}) &= \frac{-1}{2} (\mathbf{x} - \mu_i)^T \Sigma_i^{-1} (\mathbf{x} - \mu_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i| \\ &\quad + \ln \mathbf{P}(\omega_i) \end{aligned}$$



# 正态分布时的统计决策

## 多元正态 - 判别函数和决策面

\* 决策面方程

$$g_i(x) = g_j(x)$$

$$-\frac{1}{2}[(x - \mu_i)^T \Sigma_i^{-1}(x - \mu_i)$$

$$- (x - \mu_j)^T \Sigma_j^{-1}(x - \mu_j)] - \frac{1}{2} \ln \frac{|\Sigma_i|}{|\Sigma_j|} + \ln \frac{P(\omega_i)}{P(\omega_j)}$$

$$= 0$$

# 正态分布时的统计决策

## 多元正态 - 判别函数和决策面

\* 特殊情况1:

$$\Sigma_i = \sigma^2 I, i = 1, 2, \dots, c$$

\* 每类协方差矩阵相等，类内各特征相互独立，方差相等

\* 若先验概率  $\mathbf{P}(\omega_i) \neq \mathbf{P}(\omega_j)$

$$\Sigma_i = \begin{pmatrix} \sigma^2 & \dots & 0 \\ \dots & \sigma^2 & \dots \\ 0 & \dots & \sigma^2 \end{pmatrix}, |\Sigma_i| = \sigma^{2d}, \Sigma_i^{-1} = \frac{1}{\sigma^2} I$$

# 正态分布时的统计决策

## 多元正态 - 判别函数和决策面

\* 判别函数为：

$$\begin{aligned} g_i(\mathbf{x}) &= \frac{-1}{2\sigma^2} (\mathbf{x} - \mu_i)^T (\mathbf{x} - \mu_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln \sigma^{2d} \\ &+ \ln \mathbf{P}(\omega_i) \end{aligned}$$

$$\text{即 } g_i(\mathbf{x}) = \frac{-1}{2\sigma^2} (\mathbf{x} - \mu_i)^T (\mathbf{x} - \mu_i) + \ln \mathbf{P}(\omega_i)$$

# 正态分布时的统计决策

## 多元正态 - 判别函数和决策面


\* 若先验概率  $\mathbf{P}(\omega_i) = \mathbf{P}(\omega_j)$

$$g_i(x) = \frac{-1}{2\sigma^2} (x - \mu_i)^T (x - \mu_i)$$


等价于最小距离分类器

# 正态分布时的统计决策

## 多元正态 - 判别函数和决策面



(a) 两类情况



(b) 多类情况

正态分布且  $P(\omega_i) = P(\omega_j)$ ,  $\Sigma_i = \sigma^2 \mathbf{I}$  时的决策面

# 正态分布时的统计决策

## 多元正态 - 判别函数和决策面

\* 特殊情况2:

$$\Sigma_i = \Sigma, i = 1, 2, \dots, c$$

\* 每类协方差矩阵相等

$$* \mathbf{g}_i(\mathbf{x}) = \frac{-1}{2} (\mathbf{x} - \mu_i)^T \Sigma_i^{-1} (\mathbf{x} - \mu_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i| + \ln \mathbf{P}(\omega_i)$$

# 正态分布时的统计决策

## 多元正态 - 判别函数和决策面

可简化为  $g_i(\mathbf{x}) = \frac{-1}{2} (\mathbf{x} - \mu_i)^T \Sigma_i^{-1} (\mathbf{x} - \mu_i) + \ln \mathbf{P}(\omega_i)$


\* 当先验概率相等时

$$g_i(\mathbf{x}) = \gamma^2 = (\mathbf{x} - \mu_i)^T \Sigma_i^{-1} (\mathbf{x} - \mu_i)$$

即为马氏距离

# 正态分布时的统计决策

## 多元正态 - 判别函数和决策面



正态分布且  $P(\omega_1) = P(\omega_2)$ ,  $\Sigma_1 = \Sigma_2$  时的决策面



# 正态分布时的统计决策

## 多元正态 - 判别函数和决策面

\* 特殊情况3:

$$\Sigma_i \neq \Sigma_j$$


\* 各类协方差矩阵不相等

$$\begin{aligned} g_i(x) &= \frac{-1}{2} (x - \mu_i)^T \Sigma_i^{-1} (x - \mu_i) - \frac{1}{2} \ln |\Sigma_i| \\ &\quad + \ln \mathbf{P}(\omega_i) \end{aligned}$$


\* 决策面:  $g_i(x) - g_j(x) = 0$

# 正态分布时的统计决策


## 多元正态 - 判别函数和决策面




(a) 圆




(b) 椭圆



(c) 抛物线



(d) 双曲线



(e) 直线

谢谢